PREPARAÇÃO PARA A BANCA / 01

O que você precisa entender

Guia de estudo e fala | Projeto do seguro empresarial | Versão 2

A ideia em uma frase: usamos uma regressão para transformar dados da empresa em um índice explicável, que ajuda o gestor a discutir um plano de seguro.

1. Regressão logística: o que é?

É um método que relaciona características de um caso a probabilidades de categorias. No nosso projeto, as características são dados como funcionários, estoque e bens; as categorias são os três planos. Apesar do nome “regressão”, aqui ela ajuda a classificar.

2. Por que a nossa é ordinal?

Porque consideramos uma ordem de abrangência: **Essencial → Prático → Total**. O modelo usa uma pontuação comum e dois limites para separar essa ordem. “Mais abrangente” não significa automaticamente “melhor para qualquer empresa”.

3. O que o modelo aprendeu e o que nós definimos?

Nós definimos a referência: critérios associados às coberturas, porque a base mock não traz o plano adequado de cada empresa. **A regressão aprendeu:** os pesos das variáveis e os dois limites, tentando reproduzir essa referência.

4. Como nasce o score?

Dados tratados → soma dos pesos × variáveis → z → função logística → score.

$$z = \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p$$
$$\text{score} = 1 / (1 + \exp(-z))$$

β, lido “beta”, é o peso; x é o dado transformado. Peso positivo tende a elevar o índice, mantendo o restante constante. Números passam por logaritmo e padronização; por isso, não multiplicamos os pesos diretamente pelos reais ou pelo número bruto de empregados.

5. O que o score não significa?

Score de 0,80 **não significa 80% de chance de compra**. Ele posiciona o estabelecimento na escala do modelo. As probabilidades dos três planos são outra saída, e se referem à política construída.

O que falar em cerca de 2 minutos

1. Objetivo e método

Nosso objetivo é apoiar o gestor na indicação de seguro empresarial com um índice explicável. Usamos regressão logística ordinal porque os planos seguem uma progressão de coberturas: Essencial, Prático e Total. O modelo aprende relações entre as características da empresa e essa ordem de planos.

2. Origem das referências

Trabalhamos com a base mock fornecida pelo desafio. Ela não informa o plano adequado de cada empresa. Por isso, construímos referências com critérios documentados, ligados às coberturas: empregados como sinal de prioridade para responsabilidade do empregador, e estoque e bens como sinais de proteção patrimonial. Esses critérios são hipóteses da equipe, não regras oficiais do BB.

3. Pesos e faixas

A regressão estima os pesos das variáveis e dois limites. A soma das contribuições passa por uma função logística, gerando o score entre zero e um. A mesma transformação converte os limites nas faixas dos planos. Portanto, as faixas são aprendidas a partir da referência; não foram escolhidas diretamente. O score não representa chance de compra.

4. Avaliação e resultado

Comparamos modelos com oito, nove e dez variáveis, separando empresas entre treino e validação. O modelo de oito teve o melhor resultado interno. No teste comum, reproduziu cento e quatorze de cento e quarenta e quatro referências, cerca de setenta e nove por cento. Esse teste já havia sido usado na versão anterior. O resultado mede concordância com nossa política, não prova de plano ideal. A contribuição é oferecer um índice contínuo e contribuições rastreáveis para apoiar a análise do gestor.

Como ensaiar: são aproximadamente 238 palavras. A 130 palavras por minuto, a fala dura cerca de 1.8 minutos, antes de pausas. Cronometre duas leituras em voz alta; fale com suas palavras, preservando a distinção entre referência construída e resultado observado.

Use um único slide de apoio: “dados → referência → regressão → score e faixas”. Mostre 8 variáveis e 114/144. Não tente recitar todos os coeficientes ou os limites com nove casas decimais.

Perguntas mais prováveis

“De onde vieram os planos usados no treino?”

“Nós os construímos na base mock. A política central prioriza Total a partir do percentil 75 de empregados; depois, Prático a partir do percentil 60 de estoque ou bens; o restante fica como Essencial. São hipóteses do protótipo, não planos observados nem limites oficiais do BB.”

“Como vocês escolheram esses percentis?”

“São uma convenção inicial de priorização relativa à base, documentada antes do teste. Não existe prova de que sejam os melhores limites comerciais. Na versão anterior, alteramos esses critérios e vimos mudanças relevantes nas indicações.”

“Como chegaram às faixas do score?”

“A regressão aprendeu dois limites na escala z: aproximadamente -0,9241 e 4,5636. Aplicando a função logística, eles viram 0,2841 e 0,9897. Usamos esses pontos para decidir pela mediana da distribuição prevista. Os limites refletem a referência que construímos.”

“Por que a faixa do Total é tão pequena?”

“A função logística comprime pontuações altas perto de um. Uma faixa estreita não significa poucos casos: o modelo indicou Total para 31 dos 144 estabelecimentos de teste.”

“O que quer dizer 79,17%?”

“O modelo reproduziu 114 de 144 referências construídas. Não significa que acertou o plano ideal de 79,17% dos clientes. As bases não compartilham empresas, mas o teste foi reavaliado após a primeira versão.”

“Por que oito variáveis, se três já funcionavam?”

“Comparamos oito, nove e dez dentro do escopo definido, buscando incluir contexto. Oito foi a melhor dessas opções. A versão anterior de três teve 80,56% no mesmo teste; portanto, não afirmamos que adicionar variáveis trouxe ganho.”

Se der branco: retome a sequência “referência construída → pesos aprendidos → faixas estimadas → teste de concordância”. Ela explica a lógica inteira sem depender de jargão.

Se a banca aprofundar

“Qual R^2 vocês usaram?”

“Pseudo-R^2 de McFadden: 1 menos a razão entre a log-verossimilhança do modelo e a do modelo nulo. No treino, ficou em 0,6488. Na validação, o índice preditivo equivalente ficou em 0,6458. Isso não é percentual de variância explicada nem taxa de acerto.”

“Como evitaram que o modelo decorasse os dados?”

“Separamos as empresas em três divisões para validação, mantivemos seus estabelecimentos juntos e ajustamos transformações e critérios só no treino de cada divisão. Também comparamos três penalidades de regularização. São medidas de controle; não eliminam todo risco de sobreajuste.”

“Todas as variáveis são significativas?”

“Não fizemos uma afirmação confirmatória de significância. Verificamos estabilidade com cem reamostragens por empresa. Funcionários, estoque e bens mantiveram sinal positivo; faturamento e área tiveram intervalos que cruzam zero. Os resultados dependem da política construída.”

“Qual hipótese importante a ordinal faz?”

“Ela usa os mesmos pesos para as duas separações entre planos: é a hipótese de chances proporcionais. Não a confirmamos formalmente. Um comparador multinomial foi melhor na classificação interna da v1; a ordinal foi mantida pelo objetivo de produzir um índice único com faixas.”

“Se vocês criaram a regra, por que usar regressão?”

“A regra direta reproduziria nossa referência em 100% dos casos por definição. A regressão a aproxima e gera um índice contínuo com contribuições. Esse é o objetivo do protótipo, não uma prova de que a regressão é melhor que a regra ou aumenta vendas.”

“O que significa regularização ou log-loss?”

“Regularização penaliza pesos excessivos. Log-loss mede a qualidade das probabilidades e penaliza previsões erradas muito confiantes; quanto menor, melhor. Escolhemos o modelo pela log-loss da validação, não pelo resultado do teste.”

Uma resposta segura quando faltar evidência: “Esse ponto ainda não foi validado. O que medimos foi a concordância com a política na base mock.” Evite dizer “o modelo provou” ou “o score garante”.

Sua cola antes de apresentar

Lembrete	Resposta curta
Objetivo	Apoiar a análise do gestor com índice explicável.
Modelo	Regressão logística ordinal, com regularização L2.
Desenvolvimento	2.978 estabelecimentos, de 2.500 empresas.
Teste comum	144 estabelecimentos, de 120 empresas.
Comparações	8, 9 e 10 variáveis; 3 penalidades; 3 divisões = 27 ajustes.
Versão escolhida	8 variáveis originais; 17 coeficientes após codificação.
Resultado externo	114/144 = 79,17% de concordância; não plano ideal.
Faixas aproximadas	Essencial < 0,2841; Prático < 0,9897; Total a partir daí.
Variáveis	Funcionários, estoque, bens, receita, nº de estabelecimentos, atividade, tipo de unidade e área.
Principal limite	A referência vem de critérios propostos pela equipe.

Três cuidados para não se contradizer

1. Diga “concordância com a referência”, não “acerto do plano ideal”.
2. Diga “os pesos foram aprendidos”, sem esconder que os critérios de referência foram definidos por nós.
3. Diga “apoio à decisão”, não “contratação automaticamente aprovada”.

O que estudar primeiro

Leia a página 1; pratique a fala da página 2 duas vezes; peça para alguém fazer as perguntas das páginas 3 e 4. Não precisa decorar fórmulas longas. Precisa conseguir explicar **qual é o alvo, de onde ele veio, como o score é calculado e o que o teste realmente mediu**.

Base das explicações

Resultados: entrega indice_regressao_v2, resultado.json, resumo_8_9_10.csv e pesos.csv. Critérios: versão central congelada na v1 e mantida na v2. Data de referência: 28/10/2026.

Método: statsmodels - regressão ordinal; modelo de chances proporcionais; pseudo-R^2 de McFadden. São referências conceituais; os números apresentados vêm da execução do projeto.