PROJETO DO HACKATHON / 01

Um índice para apoiar a venda de seguro empresarial

Resumo do núcleo estatístico | Versão 2 | 28 de outubro de 2026

A proposta é ajudar o gestor a olhar o perfil de uma empresa e iniciar uma conversa mais informada sobre seguro. Para isso, transformamos dados do negócio em um **score de 0 a 1**, associado a uma indicação entre os planos Essencial, Prático e Total.

O score é calculado por uma regressão logística ordinal: um modelo que aprende relações entre variáveis e categorias ordenadas. A ordem usada acompanha a progressão das coberturas dos três planos.

2.978	8	79,17%
estabelecimentos no desenvolvimento	variáveis no modelo escolhido	concordância no teste mock

A ideia em cinco passos

Passo	O que fizemos
1. Organizar	Reunimos cadastro, estabelecimentos, sinais operacionais e bens.
2. Criar uma referência	Associamos planos aos perfis mock por critérios documentados.
3. Treinar	A regressão estimou pesos das variáveis e dois limites de separação.
4. Avaliar	Comparamos versões e verificamos previsões em empresas separadas.
5. Explicar	Entregamos score, faixa, plano sugerido e contribuição das variáveis.

O que o resultado significa: a recomendação reproduz uma política construída para a competição. Não é uma comprovação de qual plano é ideal, nem uma probabilidade de compra. A decisão comercial continua exigindo confirmação das necessidades do cliente.

Quais dados entram no cálculo?

Usamos a **base mock fornecida pelo desafio**. O desenvolvimento tem 2.500 empresas e 2.978 estabelecimentos; o teste comum, 120 empresas e 144 estabelecimentos. Uma empresa pode ter mais de um endereço e receber scores diferentes por estabelecimento.

Variável	O que representa e por que entra
Funcionários estimados	Tamanho da equipe da empresa; sinal indireto para discutir proteção ligada ao empregador.
Estoque médio	Valor estimado do estoque do estabelecimento; contexto de exposição patrimonial.
Bens ponderados	Valor dos bens considerando a força do vínculo cadastral com o estabelecimento.
Faturamento mensal	Escala econômica da empresa; avaliado como informação adicional ao número de funcionários.
Número de estabelecimentos	Quantidade de endereços cadastrados para a empresa na base.
Atividade econômica	Contexto da operação: mercado, oficina, escola, escritório e outros segmentos.
Tipo de unidade	Diferencia matriz e filial.
Área do imóvel	Tamanho cadastrado do estabelecimento, quando disponível.

Como preparamos a base

Cada linha final representa um estabelecimento. Ligamos o cadastro da empresa ao endereço, aos sinais operacionais e aos bens. Os bens foram agregados antes da junção para evitar multiplicar linhas. Identificadores servem para ligar e conferir registros; não são preditores.

Valores numéricos ausentes recebem a mediana aprendida no treino. A área está ausente em aproximadamente **61,7%** do desenvolvimento; por isso, o modelo também recebe um indicador dessa ausência. Depois, aplicamos logaritmo e padronização. As categorias viram indicadores numéricos.

Atenção à escala: funcionários e faturamento são da empresa inteira. Não os dividimos automaticamente entre endereços. As oito variáveis originais se transformam em **17 coeficientes**, por causa das categorias e do indicador de ausência.

PROJETO DO HACKATHON / 03

Como criamos os planos de referência

A base informa os perfis empresariais, mas não informa qual seria o plano adequado para cada empresa. Para viabilizar o experimento, construímos uma referência transparente. O catálogo fundamenta a ligação com as coberturas; **a política de associação é uma hipótese da equipe**.

Plano	Ligação com as coberturas do catálogo
Essencial	Conjunto inicial: incêndio/raio/explosão/fumaça, danos elétricos, aluguel, RC estabelecimento e despesas fixas.
Prático	Acrescenta proteção patrimonial contra roubo/furto mediante arrombamento e eventos de vendaval.
Total	Acrescenta responsabilidade civil do empregador e quebra de vidros.

Política central, com prioridade nesta ordem

Referência	Critério aplicado na base de desenvolvimento
1. Total	Funcionários estimados da empresa no percentil 75 ou acima: 17 ou mais.
2. Prático	Entre os demais casos: estoque no percentil 60 ou acima (cerca de R$ 39.670), OU bens no percentil 60 ou acima (R$ 196.460).
3. Essencial	Demais casos, como categoria residual da política.

Percentil é uma posição na distribuição dos dados. O percentil 75 deixa aproximadamente 75% dos valores abaixo ou até esse ponto. Usá-lo cria uma prioridade relativa à base, não um limite universal de risco.

Escolhemos esses percentis como convenção inicial, antes da avaliação do teste. Na validação interna, eles são recalculados apenas na parte usada para treinar. Os valores completos, sem arredondamento, ficam registrados nos arquivos do modelo.

O que não podemos concluir: poucos empregados não significam ausência de necessidade de RC empregador, e estoque baixo não significa ausência de risco. Também não inferimos vidros, vendaval ou elegibilidade a partir de sinais insuficientes.

Fonte das coberturas: catálogo do desafio e página oficial BB Seguros. Os percentis não são regras oficiais do BB. Referências ao final.

Como a regressão aprende os pesos

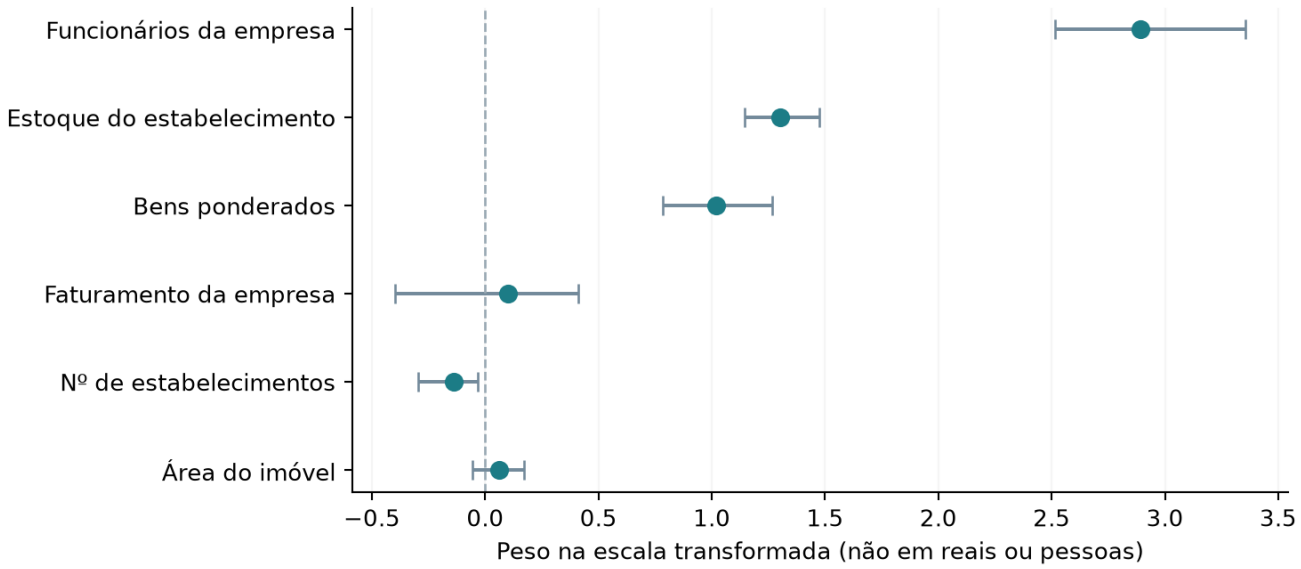
Depois de criar a referência, mostramos ao modelo as variáveis de cada estabelecimento e seu plano de referência. O ajuste procura pesos e limites que atribuam boas probabilidades a essas referências. A regularização reduz a tendência a usar pesos excessivos.

$$z = \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Aqui, **x** é uma variável já tratada, **β** é seu peso e **z** é a pontuação antes de virar score. Cada parcela β × x é uma contribuição. Peso positivo tende a elevar o índice, mantendo as outras variáveis constantes; não prova causa e efeito.

$$x_j = \frac{\ln(1 + v_j) - \mu_j}{\sigma_j}$$

Para números como reais e funcionários, usamos log(1 + valor) e depois retiramos a média do treino e dividimos pelo desvio padrão. Isso reduz diferenças de escala. As categorias recebem indicadores 0/1, com uma categoria de comparação.



Como ler o gráfico: o ponto é o peso estimado. A barra mostra um intervalo de estabilidade obtido com 100 reamostragens por empresa. Ele é condicionado à política, à transformação e às variáveis escolhidas. Não é um teste confirmatório de significância.

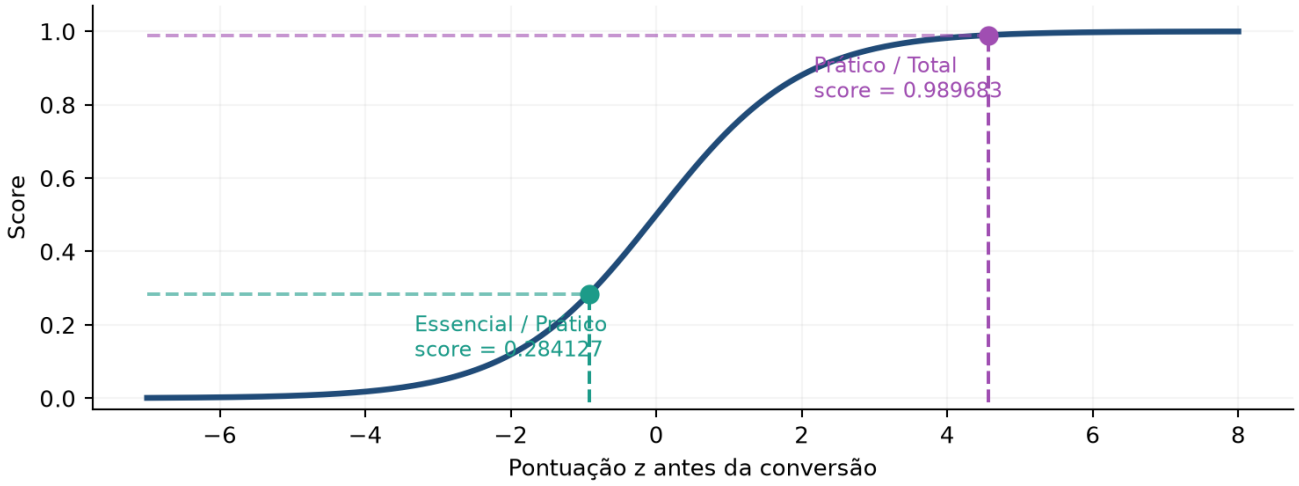
Funcionários, estoque e bens tiveram sinais positivos estáveis. Faturamento e área tiveram intervalos que cruzam zero: **não confirmamos que todas as oito variáveis tenham efeito estável**. Atividade possui pesos diferentes por categoria, e não um único peso universal.

De onde vêm o score e suas faixas?

A regressão produz a pontuação z e aprende dois limiares nessa escala: **t_1 = -0,924080316** e **t_2 = 4,563579388**. Aplicamos a mesma função logística à pontuação e aos limiares para colocá-los entre 0 e 1.

$$S = \frac{1}{1 + e^{-z}}$$

Aplicação da fórmula	Resultado na versão 2
S = logística(z)	Score de cada estabelecimento.
a = logística(t_1)	0,284127232: limite entre Essencial e Prático.
b = logística(t_2)	0,989682875: limite entre Prático e Total.



A indicação segue a **mediana da distribuição prevista**: Essencial abaixo de a; Prático de a até abaixo de b; Total a partir de b. No primeiro limite, a probabilidade acumulada de Essencial é 50%; no segundo, a acumulada de Essencial + Prático é 50%. Não é necessariamente a classe com maior probabilidade.

A faixa do Total fica estreita porque a curva comprime pontuações altas perto de 1. Isso não implica poucos clientes nessa faixa. O código usa os valores completos; não arredonda o score antes de decidir.

Exemplo da base mock: no estabelecimento IMO_CASO_00047_01, a soma de todas as contribuições foi z = -0,822899. A fórmula resulta em **score = 0,305149**, na faixa Prático. A referência construída desse caso era Essencial: este exemplo também mostra que o modelo pode divergir da regra que aprendeu.

O que os testes mostraram?

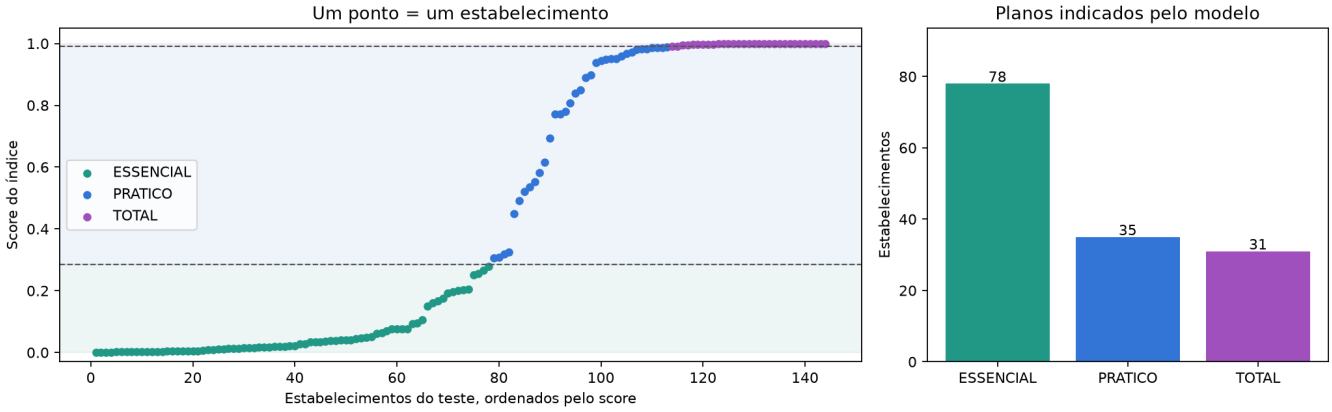
Comparamos 8, 9 e 10 variáveis, cada conjunto com três intensidades de regularização e três divisões de treino/validação: **27 ajustes**. Estabelecimentos da mesma empresa ficam juntos. A melhor versão foi escolhida pela menor log-loss de validação, que mede a qualidade das probabilidades.

Variáveis	Pseudo-R² no treino	Índice preditivo na validação	Concordância na validação
8 - escolhida	0,6488	0,6458	83,48%
9	0,6489	0,6449	83,31%
10	0,6490	0,6448	83,28%

$$R^2_{\text{McFadden}} = 1 - \frac{LL_{\text{modelo}}}{LL_{\text{nulo}}}$$

O pseudo-R² de McFadden compara a log-verossimilhança do modelo à de um modelo que usa só as frequências dos planos. Na validação usamos uma razão equivalente fora da amostra. **0,6458 não significa 64,58% de acerto nem de variância explicada.** A penalidade não entra no cálculo dessa razão.

Índice v2 — 144 estabelecimentos da base de teste



Faixas: Essencial < 0.284127 | Prático < 0.989683 | Total ≥ 0.989683
Referências construídas na base mock. Score não é chance de compra.

Teste comum: 114 de 144 referências reproduzidas, ou 79,17%. O modelo indicou 78 Essenciais, 35 Práticos e 31 Totais. A concordância mede reprodução dos critérios construídos, não acerto sobre o plano ideal. Cada ponto do gráfico representa um estabelecimento.

A versão de 3 variáveis anterior teve 80,56% no mesmo teste. A exigência de pelo menos 8 variáveis foi atendida, mas não trouxe ganho observado. O teste já havia sido consultado antes: esta é uma reavaliação, não uma nova validação intocada.

O que está pronto

O que foi entregue e conferido

Entregamos dados preparados, critérios, código, modelo, pesos, faixas e notebooks executados. Um painel local permite consultar os scores e gráficos por estabelecimento.

A versão portátil reproduziu scores, probabilidades e planos nos **3.122 registros** de desenvolvimento e teste, com diferença numérica desprezível. Ela também trata dados ausentes, categorias desconhecidas e números inválidos. Isso verifica consistência técnica, não a adequação comercial da indicação.

Limites que fazem parte do resultado

Ponto	Interpretação correta
Referência construída	Os pesos aprendem uma política da equipe. Uma regra direta reproduziria essa referência em 100% dos casos por definição; a regressão oferece uma escala contínua e contribuições.
Sensibilidade às escolhas	Na v1, critérios alternativos mudaram cerca de 21% a 23% das indicações internas. Essa medição não foi refeita especificamente na v2.
Restrição do modelo ordinal	O comparador multinomial da v1 classificou melhor internamente. O índice único com faixas tem um custo de flexibilidade; não foi demonstrado como o melhor classificador geral.
Qualidade dos dados	Área tem muitas ausências; empregados e receita são da empresa. Esses limites precisam acompanhar a recomendação.
Uso comercial	Ainda não medimos aumento de vendas, satisfação, preço adequado ou escolha ideal. Necessidades e elegibilidade precisam de confirmação.

Mensagem para apresentar: “Construímos um índice explicável por regressão sobre a base mock do desafio. Ele aprende uma política transparente de enquadramento e ajuda o gestor a organizar a análise. Os testes mostram sua consistência e também os limites dessa política.”

Fontes e rastreabilidade

Dados: CSVs mock do Seguro Empresarial fornecidos no desafio; bases de desenvolvimento e teste comum. Resultados: arquivos da entrega **indice_regressao_v2**, principalmente resultado.json, resumo_8_9_10.csv, pesos.csv e formula_completa.json. Versão consolidada em 28/10/2026.

Coberturas: BB Seguros - Seguro Empresarial e catálogo do desafio. Método: documentação statsmodels - pseudo-R^2 de McFadden. A versão das condições e a aceitação de risco devem ser conferidas em uma contratação.